

WiFall: Device-Free Fall Detection by Wireless Networks

摘要

跌倒损伤已成为影响老年人独立生活的主要健康威胁之一。传统的跌落检测系统有各种各样的局限性。在本文中，首先通过分析无线电传播模型来寻找不同无线电信号变化与活动之间的相关性。本文采用物理层通道状态信息 (CSI) 作为活动的指示器。它可以检测人的跌倒等行为，无需硬件修改，额外的环境设置，或任何可穿戴设备。我们在配备两台利用 USRP N210 以及一台笔记本上实现了跌倒检测功能，并在致腾楼 10 层信号屏蔽室的室内场景下评估了跌倒检测的性能。在进行实验的场地，本文可以实现对单个人的有效跌倒检测。实验结果表明，在所有测试位置上，使用单类 SVM 分类器，跌倒的检测精度为 93.72%。使用随机森林算法，跌倒的检测精度为 89.13%。使用 CNN 的跌倒检测精度为 85.19%。使用联合卷积神经网络的长短时记忆网络即 CNN-LSTM 的跌倒的检测精度为 90.67%。

关键词：channel state information; fall detection

1 引言

老年人跌倒是一种常见但危险的现象，据美国疾病控制与预防中心数据显示，65 岁及以上的成年人中有三分之一每年至少经历一次跌倒。这些跌倒事件往往导致严重的伤害，甚至危及生命。及时的跌倒检测与救援可以显著提高老年人的生存率。为了在家庭环境中实现自动跌倒检测，目前存在基于环境设备、摄像头、可穿戴传感器和智能手机的跌倒检测系统。然而，这些系统存在一些问题，如高成本、侵犯隐私、佩戴不便等。为了克服这些问题，研究者们提出了一种创新的技术——基于无线局域网 (WLAN) 的老年人室内跌倒检测系统。通过利用 WiFi 信号在传播中的特性，该系统采用了商用无线产品，无需特殊可穿戴设备，实现了高精度、低成本、用户友好的跌倒检测。过去十年中，WiFi 技术已引起广泛关注，涉及定位、运动检测和目标跟踪等领域，为实现无线信号与人类活动的关系研究提供了契机。针对现有无线电传播模型难以适用于复杂人类活动的问题，本文通过研究人类活动干扰下的室内无线传播模型，提出了一种改进的理论模型。在此基础上，文中利用通道状态信息 (CSI) 作为指示器。通过设置定义 WiFi 信号通信链路覆盖的摔倒检测区域，实现了对有效距离内单个人各种活动的有效检测，特别是在非目视点位置的情况下。

2 相关工作

2.1 穿戴式和非可穿戴式检测

在可穿戴技术领域，人们提出了多种跌倒传感器，包括心电图、加速度计、RFID、陀螺仪、压力传感器和智能手机。尽管在室外环境中佩戴传感器效果显著，但老年人可能不始终遵循这一操作 [1]。值得注意的是，在独立生活的老年人中，约有一半的跌倒事件发生在自己的住所 [2]，这强调了需要一种可靠的非穿戴式室内跌倒检测解决方案。在非可穿戴技术中，基于计算机视觉的方法通常具有高准确性，但存在隐私和遮挡等问题 [3] [4]。环境传感方法涉及麦克风阵列、压力传感器和振动传感器，通过测量环境变化来检测跌倒，但可能受到其他环境源的干扰而产生误报 [5]。

无线技术包括雷达、WiFi 信号等无线通信信号信息以及无线传感器网络。一些系统利用环境设备或地板振动检测跌倒，但需要特定装置的事先植入 [6] [7]。使用摄像机的系统能够通过高分辨率图像记录和活动分类算法有效地检测跌倒，然而，摄像机成本昂贵且可能侵犯个人隐私 [8] [9]。

基于可穿戴传感器和智能手机的 Fall Detection (FD) 技术使用加速度或速度变化感知跌倒。然而，携带传感器或智能手机对用户不便，且不同位置的传感器可能导致不同的检测性能。例如，一些系统需要用户携带定制设备，如由加速度计、微控制器和其他传感器组成的设备 [10]，而其他系统则仅需携带智能手机 [11]，但放置位置可能影响检测精度。这突显了在开发跌倒检测技术时需平衡准确性、便利性和隐私等多个因素。

2.2 通道状态信息 (CSI)

信道状态信息或信道状态信息 (Channel State Information, CSI) 是估计通信链路 [12] 的信道属性的信息。在无线通信中，发射的无线电信号受到物理环境 (例如，反射、衍射和散射) 的影响。CSI 描述了信号如何通过结合时间延迟、幅度衰减和相移的影响在信道中传播。在频域，多收发天线 (多输入多输出, MIMO) 窄带平衰落信道建模为：

$$y = Hx + n \quad (1)$$

其中， y 为接收矢量， x 为发射矢量， n 为噪声矢量， H 为信道矩阵。由于噪声常被建模为 $n \sim \mathcal{CN}(0, S)$ 的圆对称复高斯，故上式中的 H 可估计为：

$$\tilde{H} = \frac{y}{x} \quad (2)$$

在正交频分复用 (OFDM) 系统中，CSI 在子载波级表示。单个子载波的 CSI 采用以下数学格式：其中 $|h|$ 是振幅， θ 是每个子载波的相位。

$$h = |h|e^{j\sin\theta} \quad (3)$$

与接收信号强度 (Received Signal Strength, RSS) 相比，CSI 提供了更细粒度的无线链路表示。因此，最近的无线应用程序倾向于使用 CSI 而不是 RSS。本文将对如何利用 CSI 来表示人类活动进行实验分析。

2.3 网络模型

为了从数百万张图像中学习成千上万种物体，我们需要拥有强大学习能力的模型。然而，物体识别任务的巨大复杂性表明，我们的模型需要具备大量的先验知识，以弥补我们缺乏的所有数据。卷积神经网络（CNNs）是解决这类问题的一种重要模型之一 [13]。长短期记忆网络（LSTM）最早于 1997 年提出。它是一种特殊类型的 RNN，适合于对时间序列中间隔和延迟相对较长的情形进行处理和预测。但 CNN 只是利用了图像所具有的空间信息，图像在被观测记录时已经把时间信息包含进去，所以不应该忽视它。由于 LSTM 时间预测上的良好性能，所以我们使用网络优化，及引入了联合卷积神经网络的长短时记忆网络即 CNN-LSTM，通过卷积网络提取出图像特征，并将其输入到长短时记忆网络中，而后将特征传递到回归层完成最终的分类。

3 本文方法

3.1 方法概述

在实验中，数据采集阶段通过 USRP n210 配置为发射和接收模式，以及使用 16QAM 调制方式，使得获得的原始数据能够准确反映 WiFi 信号的特征。数据预处理阶段则涉及将二进制文件在 Matlab 中转换为浮点数，随后解析为包含 52 个子载波的矩阵形式，为后续分析和处理奠定基础。活动提取过程包括数据处理的异常提取两个关键步骤。在数据处理中，通过 PCA 降维技术，选取第一主成分进行时序数据分析，而异常提取则运用基于梯度的方法，以获得信号变化情况，并通过自适应窗口大小精准提取具体活动。特征提取阶段着重于从异常区块中提取有意义的特征，包括归一化标准差、信号强度偏移、运动时间、中位数绝对偏差、四分位间距、信号熵以及信号变化速度标准差。这些特征成为传统机器学习分类任务的输入，其中单分 SVM 和 RF 用于训练和测试模型，七个特征用于刻画不同活动的特性。最后，手动标签的分配，包括走路、跌倒、站立和坐，为监督学习提供了标签信息，使得模型能够学习和识别这些活动。同时本文系统也使用神经网络 CNN 以及联合 CNN 的 LSTM 对运动进行检测，将截取到的活动原始数据获得的灰度图先进行通道归一化。通道归一化是对通道除以各通道的平均值。同时为增强对比度，再对归一化后的图片进行伽马变换操作和灰度拉伸操作。伽马变换是对输入图像的灰度值进行非线性操作，使输出图像灰度值呈指数关系。本文系统整体设计流程如图 1 所示。

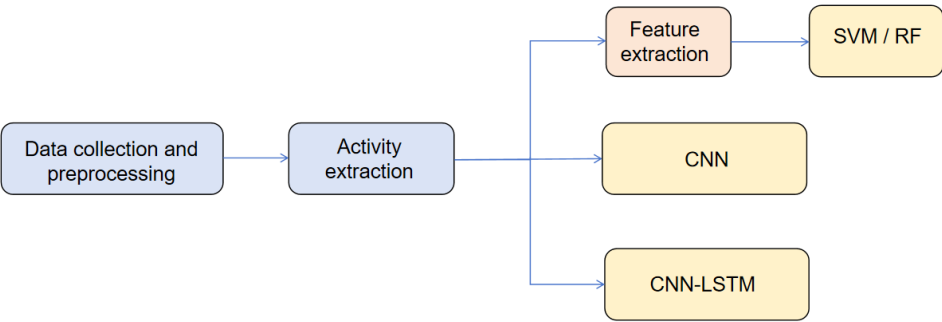


图 1

3.2 SVM/RF 特征提取模块

为了找出对分类最有用的特征，我们首先选择最常用的特征来表征活动，即 CSI 的归一化标准差、信号强度偏移、运动周期、中位数绝对偏差、四分位间距、信号熵和信号变化速度。我们选取的七个特征的含义如下：

- 1) 标准化 STD: 与运动的动态范围有关。
- 2) 信号强度偏移量: 对应于 MPs 接收到的最强功率。
- 3) 运动周期: 表示活动持续的时间。
- 4) 中位数绝对偏差 (MAD): MAD 是定量数据单变量样本可变性的稳健度量。平方和 MAD 可以表示数据的集中程度。
- 5) 四分位间距 (Interquartile Range, IR): 对应 CSI 的离散度。
- 6) 信号熵: 它是系统无序的一般度量。
- 7) 信号变化的速度: 速度在这里被计算为一阶导数，这是一个表明信号被活动改变有多快的指标。

3.3 卷积神经网络 (CNN)

对于卷积神经网络 (CNN)，它是一种针对二维数据进行处理的网络模型，本质上是一个特征提取器和分类器的结合，通过对输入数据特征的不断抽象学习，最终得到一组最接近图像含义的特征向量，然后通过最后的分类器，进行图像分类。由于卷积神经在图像分类领域有着出色效果，所以我们首先利用卷积神经网络进行实验。

3.3.1 CNN 网络模型

CNN 直接作用于原始的数据，可以自动并逐层学习图像特征，相对于手工提取特征，CNN 提取特征可以更加抽象并接近于图像的潜在特征信息，具有更好的表达能力。它由输入层，卷积层，下采样（池化层），全连接层和输出层这几部分组成，如图 2。




图 2

输入层用于接收原始图像，通常在这之前我们会进行图像预处理。卷积层用于提取图像特征，在卷积层中，每个卷积核都被看作一个滤波器来对局部数据进行计算，并通过滑动窗口提取目标的特征图像，在完成卷积计算后，得到的特征图输入到非线性函数（激活函数）中去，得到输出矩阵即特征图。假设输入的原始图像为 X ， Y_i 为第 i 层的特征图， $Y_0 = X$ 。则有公式 $Y_i = f(W_i \cdot Y_{i-1} + b_i)$ 。其中： W_i 表示第 i 层卷积核的权重； b_i 表示第 i 层的偏置向

量，运算符 \cdot 表示 W_i 与第 $i-1$ 层的特征图进行卷积操作； f 表示非线性激活函数，通常采用 ReLU 激活函数，ReLU 表达式为：

$$f(x) = \begin{cases} 0, & x < 0 \\ x, & x \geq 0 \end{cases} \quad (4)$$

下采样层也称为池化层，一般在卷积层之后，基于图像的局部相关性对特征图进行降维操作，保留图像局部特征的有效信息的同时，降低输入特征矩阵的大小。假设 Y_i 为下采样特征图，则

$$Y_i = \text{subsample}(Y_{i-1}) \quad (5)$$

在全连接层中，通过卷积和池化得到的特征图会被重组成一维向量层的输入，假设 Y_i 为第 i 层全连接层，则：

$$Y_i = f(W^t Y_{i-1} + b^t) \quad (6)$$

其中： W^t 是权重系数矩阵， b^t 是第 t 层的偏置项。全连接层之后，需要对实体的概率进行分析，使用 Softmax 函数用于完成最终的分类任务，Softmax 的预测函数如下所示：

$$f_{\theta}(x) = \begin{cases} p(y^i = 1|x^i; \theta) \\ p(y^i = 2|x^i; \theta) \\ \vdots \\ \vdots \\ p(y^i = k|x^i; \theta) \end{cases} = \frac{1}{\sum_{j=1}^k \theta^{\theta^T x^j}} \begin{cases} \theta^{\theta_1^T x^j} \\ \theta^{\theta_2^T x^j} \\ \vdots \\ \vdots \\ \theta^{\theta_k^T x^j} \end{cases} \quad (7)$$

其中 θ_a 为所求的网络参数， $\frac{1}{\sum_{j=1}^k \theta^{\theta^T x^j}}$ 是归一化因子，目的是为了保持所有结果概率和为 1。其损失函数公式如下所示：

$$f(x) = -\frac{1}{m} \sum_{i=1}^m \sum_{j=1}^n \{y^i = j\} \left(\log \frac{e^{\theta_j^T x^j}}{\sum_{j=1}^k e^{\theta_j^T x^j}} \right) \quad (8)$$

3.3.2 CNN 结构设计

针对预处理之后的 $300 * 52$ 的图像矩阵，本次实验进行两次特征提取，前两层由 32 个 $3*3$ 的卷积核和 $2*2$ 的最大池化层组成，形成 $32 * 25 * 50$ 的特征矩阵；之后在通过 64 个 $3*3$ 的卷积核以及 $2*2$ 的最大池化层，形成 $64 * 11 * 23$ 的特征矩阵。最后是 4 层卷积层，来研究研究跌倒的分类效果。然后通过依次拥有 256 神经元和 64 神经元，激活函数为 Relu 的全连接层，然后输出到分类层中，得到分类结果。

3.4 联合 CNN 的 LSTM

3.4.1 LSTM 网络模型

LSTM 网络结构如图 3 所示。该网络的门限机制使得它可以维持较长的时间储存信息，进而避免了梯度消失的问题。每个单元中被放置了输入门、遗忘门和输出门，三个门利用了

sigmoid 激活函数来控制网络中信息的传递，分配给当前时刻一定的信息，再分配给下一时刻网络需要的信息。

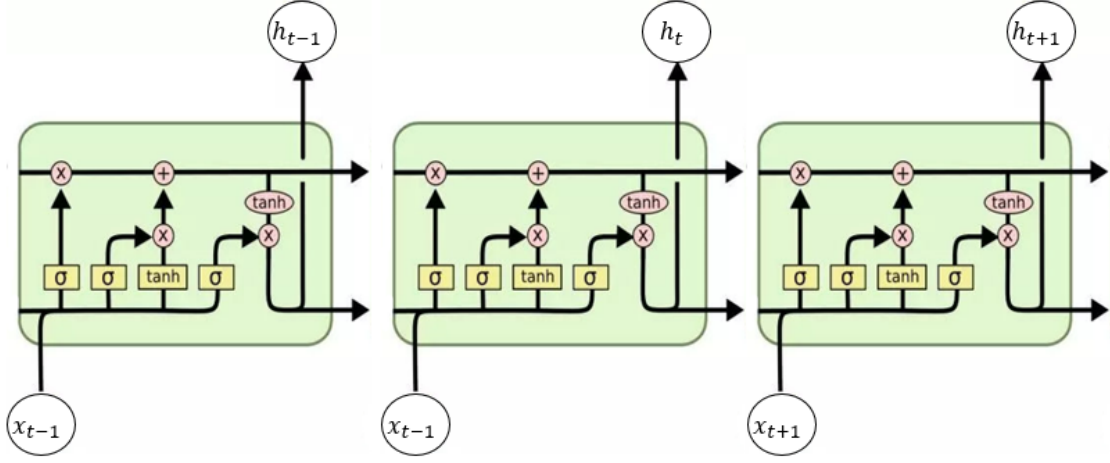


图 3

LSTM 网络首先由遗忘门来决定信息是否通过单元。根据上一时刻的输出和当前输入 x_t ，利用 sigmoid 激活函数产生一个介于 0 到 1 的值 f_t ，来决定是否允许上一时刻学到的信息通过。接下来分为两部分，输入门通过 sigmoid 激活函数决定输入信息，同时输入门通过激活函数生成候选数值。然后通过 tanh 层构建新的候选向量 \tilde{C}_t 。接下来需要将旧的细胞状态 C_{t-1} 更新为新的细胞状态 C_t 。令 C_{t-1} 与遗忘门相乘来丢弃部分信息，同时 $i_t * \tilde{C}_t$ 用来代表更新的细胞状态。最后需要确定应该输出的内容。输入经过一层 sigmoid 层过滤掉不需要的输出；然后将细胞状态通过 tanh 函数，使得细胞状态中的取值在 -1 和 1 之间。将上面两者相乘，就可以得到需要的输出。对应的公式如下：

$$\begin{cases} f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \\ i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \\ o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \\ \tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \\ C_t = f_t \odot C_{t-1} + i_t * \tilde{C}_t \\ h_t = f_t \odot \tanh(C_t) \end{cases} \quad (9)$$

3.4.2 网络参数设计

针对本文的频谱图像，卷积神经网络可以很好的提取出每张的视觉特征，但是这些特征不具有时序性。由于频谱图有一定的时序性，本文结合长短时记忆网络，将卷积后的特征向量 $g_v(x_i)$ 作为长短时记忆网络的输入。其中 v 表示数据经过卷积之后的权重向量。将长短时记忆网络中的前一时间步的隐藏状态记为 h_{t-1} ，当前隐藏状态为 h_t ，输出结果为 y_t 。在输入 $g_v(x_i)$ 后，首先计算 $h_1 = f_v(x_1, h_0) = f_v(x_1, 0)$ ，之后计算 $h_2 = f_v(x_2, h_1)$ ，直到计算出 h_t 结束。为了计算出时刻 t 的预测结果 y_i 的分布 $p(y_t)$ ，需要在长短时记忆网络的输出 z_t 加上线性变化，得到如下式：

$$y_t = V_z Z_t + b_z \quad (10)$$

其中表示 y_t 时刻的分类结果， V_t 表示训练之后的权重， b_z 为偏置。
最后通过 softmax 层，得到分类结果的分布如下所示：

$$P(y_t = c) = softmax(y_t) = \frac{exp(y_t, c)}{\sum_{c'=c} exp(y_t, c')} \quad (11)$$

使用交叉熵损失函数衡量模型的预测输出与实际目标之间的差异，对应的损失函数如下所示：

$$L = -\frac{1}{N} \sum_{i=1}^N \sum_{c=0}^M y_{i,c} \log\left(\frac{e^{z_{i,c}}}{\sum_{k=0}^M e^{z_{i,k}}}\right) \quad (12)$$

其中， N 是样本的数量， M 是类别数， $y_{i,c}$ 是样本 i 对应类别 c 的真实标签，是一个独热编码形式的标签。

3.4.3 结构设计

输入、输出层设计：本次实验的输入矩阵大小为 $300 * 52$ 。输出类型共 4 类，分别用数字 0, 1, 2, 3 表示，对应于行走、跌倒、坐下和站起。激活函数沿用之前实验的 ReLU 函数。

隐层网络的优化设计：针对大小为 $300*52$ 的图像矩阵进行两次特征提取。前两层由 16 个 $3*3$ 的卷积核和 $2*2$ 的最大池化层组成，形成 $16*50*26$ 的特征矩阵；之后通过 16 个 $3*3$ 的卷积核和 $2*2$ 的最大池化层，形成 $16*23*11$ 的特征矩阵。然后通过拥有 128 个神经元的 LSTM 层和一个 256 神经元的全连接层，输出一个大小为 $32*1$ 的矩阵。最后连接输出层得到分类概率，其中输出层有 4 个神经元，对应于 4 个类别。

4 复现细节

4.1 与已有开源代码对比

本文无任何相关源代码。

4.2 实验环境搭建

在特定的信号屏蔽室中使用两台 USRP N210 和一台笔记本进行数据采集。TX-RX 天线配置为 1×1 ，以包率 100 和包长 480B 发送和接收 WiFi 信号，涵盖 64 个子载波。只在链路中心进行活动并采集，对应的实验场景如图 4 所示。



图 4

4.3 数据说明

数据构成包括四种人类活动：行走、跌倒、站立和坐下，共进行 11 组实验，每组按照相同顺序执行上述四种活动，总计 154 个活动（行走 22 个、跌倒 33 个、站立 66 个、坐下 33 个）。训练与测试阶段将 80% 的数据用作训练集，20% 用作测试集，以评估模型的性能。

4.4 创新点

采用了卷积神经网络（CNN）和卷积神经网络-长短时记忆网络（CNN-LSTM）模型来处理 WiFi 信号中人类活动的分类任务。与传统方法不同，这两种深度学习模型在时序数据和频域信息的融合上展现出卓越的性能。

5 实验结果分析

5.1 SVM / RF

使用传统的机器学习 SVM 和 RF 方法对实验图像进行单分类即一次只区分是不是一种动作行为，实验结果如图 5 所示。




图 5

对实验图像进行多分类的实验结果如图 6 所示。




图 6

只区分行走的准确率很高，因为行走的运动时间比起其他三个动作，时间占比较大，特征较明显，导致行走的识别准确率很高。SVM 和 RF 对于只区分单类动作来说，准确率都较高，并且在只区分跌倒来说 SVM 优于 RF。但如果同时区分四类活动，则识别准确率都会降低，SVM 此时的识别准确率要高于 RF。可能是数据集的特征维度较高，而 SVM 在高维数据集上表现较好。

5.2 CNN

使用 CNN 方法对实验图像进行活动单分类，实验结果如图 7 所示。如图所示，使用 CNN 对各个活动进行识别的准确率都达到了 80% 以上，但基本都低于 SVM 和 RF，可能因为实验数据偏小以及实验数据类型分布不均匀导致的。




图 7

5.3 CNN-LSTM

使用 CNN-LSTM 方法对实验图像进行活动单分类，实验结果如图 8 所示。如图所示，使用 CNN-LSTM 对各个活动进行识别的准确率都达到了 90% 以上，但对于只区分跌倒以及只区分行走的准确率略微低于 SVM，其余的高于 SVM 和 RF。但总体来说，CNN-LSTM 的识别准确率高于 CNN，这验证了时间特征的可用性。




图 8

使用 CNN 和 CNN-LSTM 方法对实验图像进行多分类的实验结果如图 9 所示。CNN-LSTM 的多分类情况高于 SVM 和 RF，但 CNN 的多分类情况低于 SVM 和 RF。可能与实验数据偏小以及实验数据类型分布不均匀导致的，同时行走这个动作占据的时间长度较长也有一定影响。




图 9

与现有论文的相关跌倒检测对比如图 10 所示。相关论文的只检测跌倒的准确率可以平均达到 95% 及以上。




图 10

CNN-LSTM 和 CNN 对于行走的单分类识别准确率很高，但对于只区分其他三个动作来说，准确率较低。行走的运动时间较长导致输入进网络的数据长度也远超于其他活动数据长度，导致输入进网络的长度阈值很难设置。同时区分四类活动，CNN-LSTM 的表现最好，CNN 的表现最差。因为 CNN-LSTM 比 CNN 多利用了图像里的时间信息与特征。神经网络表现糟糕可能也因数据量较小有关。

6 总结与展望

在本文中，我们提出了一种利用通道状态信息作为指示器的跌倒检测。本文目的旨在检测跌倒，还可以识别一些其他活动。在广泛部署的现成 WiFi 基础设施中，本文利用了物理层信道状态信息。在现阶段，本文可以有效识别行走、坐下、站起来、跌倒等最常见的日常活动。可以将在今后的工作中考虑更具体的活动。与其他使用无线信号的无设备活动识别系统一样，本文目前只能针对感兴趣区域的一个人设计和测试。同时很难在多个用户中识别一个人的活动。当多人进行不同的活动时，他们的动作会对信号的传播产生巨大的相互影响。同时，由于考虑对象的数量、活动和位置的不同，会有不同的组合，使用学习方法构建训练库的成本过高。

本文虽然实现基本检测功能，但本文的数据不具有代表性和鲁棒性。数据量采集不足，同时也只在一个地方采集数据，天线阵列也只使用 1×1 。同时在活动提取的部分，阈值的设定都是根据经验设定，需要大量的数据和实验才能找到最具代表性的阈值。同时本文未达到现在多数论文达到的平均 95% 左右的跌倒检测精度。同时对于传统机器学习部分，在只区分某些情况上也可以获得更好的检测效果。对于神经网络学习，可以继续优化网络，如添加注意力机制给重要的特征赋予较高的权重。

参考文献

- [1] Y. Wang, K. Wu, and L. M. Ni. Wifall: Device-free fall detection by wireless networks. *IEEE Transactions on Mobile Computing*, 16(2):581–594, Feb 2017.
- [2] L. Day. Falls in older people: Risk factors and strategies for prevention. *Injury Prevention*, 9(1):93–94, 2003.
- [3] Leila Takayama, Caroline Pantofaru, David Robson, Bianca Soto, and Michael Barry. Making technology homey: Finding sources of satisfaction and meaning in home automation. In *Proc. of the 2012 ACM Conf. on Ubiquitous Computing*, pages 511–520. ACM, 2012.
- [4] Ossi Kaltiokallio, Maurizio Bocca, and Neal Patwari. Enhancing the accuracy of radio tomographic imaging using channel diversity. In *Mobile Adhoc and Sensor Systems (MASS), 2012 IEEE 9th International Conference on*, pages 254–262. IEEE, 2012.
- [5] H. Wang, D. Zhang, Y. Wang, J. Ma, Y. Wang, and S. Li. Rt-fall: A real-time and contactless fall detection system with commodity wifi devices. *IEEE Transactions on Mobile Computing*, 16(2):511–526, 2017.
- [6] M. Alwan, P. J. Rajendran, S. Kell, D. Mack, S. Dalal, M. Wolfe, and R. Felder. A smart and passive floor-vibration based fall detector for elderly. In *Proc. 2nd Int. Conf. Inform. Commun. Technol.*, volume 1, pages 1003–1007, 2006.
- [7] H. Rimminen, J. Lindstrom, M. Linnavuo, and R. Sepponen. Detection of falls among the elderly by a floor sensor using the electric near field. *IEEE Trans. Inform. Technol. Biomed.*, 14(6):1475–1476, Nov 2010.
- [8] H. Foroughi, A. Naseri, A. Saberi, and H. S. Yazdi. An eigenspace-based approach for human fall detection using integrated time motion image and neural network. In *Proc. 9th Int. Conf. Signal Process.*, pages 1499–1503, 2008.
- [9] H. Foroughi, B. S. Aski, and H. Pourreza. Intelligent video surveillance for monitoring fall detection of elderly in home environments. In *Proc. 11th Int. Conf. Comput. Inform. Technol.*, pages 219–224, 2008.
- [10] F. Bianchi, S. J. Redmond, M. R. Narayanan, S. Cerutti, and N. H. Lovell. Barometric pressure and triaxial accelerometry-based falls event detection. *IEEE Trans. Neural Syst. Rehabil. Eng.*, 18(6):619–627, Dec 2010.
- [11] J. Dai, X. Bai, Z. Yang, Z. Shen, and D. Xuan. Perfalld: A pervasive fall detection system using mobile phones. In *Proc. 8th IEEE Int. Conf. Pervasive Comput. Commun. Workshops*, pages 292–297, 2010.

- [12] Z. Yang, Z. Zhou, and Y. Liu. From rssi to csi: Indoor localization via channel response. *ACM Comput. Surveys*, 46(2):25, 2013.
- [13] A. Krizhevsky. Convolutional deep belief networks on cifar-10. Unpublished manuscript, 2010.